

Firat Universitesi Akademik Tesvik Asistani (LLM Fine-Tuning) - Teknik Dokuman

1. Proje Ozeti ve Amac

Bu proje, Firat Universitesi 2025-2026 Akademik Tesvik surecleri (yonetmelik, basvuru rehberi ve takvim) konusunda uzmanlasmis bir yapay zeka asistani gelistirmeyi hedefler. Amaç:

- Yonetmelik ve resmi dokumanlara dayali, tutarli ve resmi dilde yanitlar verebilen bir Soru-Cevap (QA) asistani olusturmak.
- Uctan uca bir LLM fine-tuning is akisinin (veri uretimi, on isleme, egitim, arayuz) tekrar edilebilir sekilde tanimlanmasi.
- Duset bellekli egitim icin QLoRA yaklasimindan faydalanmak.

Proje, Qwen-2.5-3B-Instruct temel modeli uzerinde LlamaFactory altyapisi ile fine-tuning yapar ve Gradio tabanlı bir demo arayuz ile servis eder.

2. Kapsam ve Sinirlar

- Kapsam: Akademik Tesvik yonetmeligi, basvuru rehberi ve takvimine dayali QA bilgisi.
- Sinirlar:
- Model yalnızca egitim verisindeki resmi dokuman icerikleriyle uyumlu bilgi uretmek uzere tasarlanmistir.
- Resmi kararlar icin tek referans kaynagi resmi dokumanlardir; model yanitlari bilgilendirme amaclidir.
- Egitim ve demo altyapisi Google Colab uzerinde kurgulanmistir.

3. Kaynak Dokumanlar

Veri uretiminin dayandigi ham kaynaklar `docs/` klasorundedir:

- `docs/Akademik\_Tesvik\_Yonetmeligi\_Basvuru\_Rehberi.docx`
- `docs/Akademik\_Tesvik\_Odenegi\_Yonetmeligi.pdf`
- `docs/Akademik\_Tesvik\_Takvimi\_2026.pdf`

Bu dokumanlar NotebookLM ile QA veri setine donusturulur.

4. Veri Uretimi (NotebookLM)

4.1. Veri Uretim Stratejisi

NotebookLM üzerine dokümanlar yüklenir ve doğrudan doküman içeriğine bağlı QA verisi üretilir. Üretimde hedef 1000 soru-cevap kayıdır.

4.2. Prompt Spesifikasyonu

NotebookLM promptu, çıktı formatını ve kuralları belirler:

KOLONLAR: "id";"question";"answer";"source_doc";"source_loc";"tags";"difficulty"

KURALLAR:

- 1) 1000 adet kayıt üret.
- 2) question: 8-25 kelime.
- 3) answer: 40-140 kelime; kısa, net.
- 4) source_doc: [Basvuru Rehberi] | [Yönetmelik] | [Takvim].
- 5) source_loc: Madde X, Tablo Y, Tarih aralığı vb.
- 6) tags: 3-6 anahtar kelime (örn: basvuru|yoksis).
- 7) difficulty: easy / med / hard.
- 8) Asla dokümanda olmayan bilgi ekleme.

4.3. Ham Veri Çıktısı

Ham çıktı CSV formatındadır:

- Dosya: `data/dataset.csv`
- Ayırıcı: `;`
- Başlık satırı mevcuttur
- Örnek sütunlar: `id`, `question`, `answer`, `source\_doc`, `source\_loc`, `tags`, `difficulty`

5. Veri Ön İşleme (CSV -> Alpaca JSON)

5.1. Amaç

LlamaFactory ile eğitim için veri, Alpaca formatında olmalıdır:

- `instruction`: soru
- `input`: (bos)
- `output`: cevap

5.2. Donusum Akisi (Training_Colab.ipynb)

Ön işleme adımı, Colab notebook içinde bir kod hücresi olarak gerçekleşir:

- CSV dosyası farklı encoding'lerle (utf-8, cp1254, latin5, vb.) okunur.
- Soru ve cevap sütunları isimlerine göre bulunur; bulunamazsa 2. ve 3. sütun varsayılır.

- Bos ya da `nan` degerler filtelenir.
- Alpaca JSON formatina donusturulur.

5.3. Cikti

- Dosya: `data/atakan\_qa.json`
- Kayit sayisi: 1000
- Ornek anahtarlar: `instruction`, `input`, `output`

6. Egitim Altyapisi ve Model Yapilandirmasi

6.1. Platform

- Ortam: Google Colab
- GPU: T4
- Framework: LlamaFactory
- Yontem: QLoRA (4-bit quantization)
- Temel model: `Qwen/Qwen2.5-3B-Instruct`

6.2. Kurulum ve Bagimliliklar

Notebook icindeki kurulum adimlari:

```
git clone --depth 1 https://github.com/hiyouga/LlamaFactory.git
pip install -e ".[torch,metrics]"
pip install bitsandbytes pandas matplotlib
```

WandB tamamen devre disi birakilir:

```
os.environ["WANDB_MODE"] = "disabled"
os.environ["WANDB_DISABLED"] = "true"
```

6.3. Egitim Konfigrasyonu

`train\_config.yaml` iceriginden ozet ayarlar:

- `stage`: sft
- `finetuning\_type`: lora
- `lora\_target`: all
- `lora\_rank`: 16
- `lora\_alpha`: 32

- ``lora_dropout`: 0.05`
- ``cutoff_len`: 1024`
- ``max_samples`: 10000`
- ``learning_rate`: 2e-4`
- ``num_train_epochs`: 3`
- ``per_device_train_batch_size`: 1`
- ``gradient_accumulation_steps`: 8`
- ``lr_scheduler_type`: cosine`
- ``warmup_ratio`: 0.1`
- ``quantization_bit`: 4`
- ``quantization_method`: bitsandbytes`
- ``val_size`: 0.1`
- ``eval_strategy`: steps`
- ``eval_steps`: 100`

6.4. Cikti ve Loglama

Egitim ciklisi Google Drive uzerinde tutulur:

- Calisma dizini: ``/content/drive/MyDrive/llamafactory_runs``
- Adapter dizini: ``/content/drive/MyDrive/llamafactory_runs/atakan_qa_qwen2.5_lora``
- Log: ``training_log.txt``
- Ek loglar: ``trainer_log.jsonl``, ``training_loss.png``

Egitim komutu:

```
llamafactory-cli train /content/train_config.yaml 2>&1 | tee "/content/drive/MyDrive/llamafactory_runs
```

7. Degerlendirme ve Izleme

Notebook, ``trainer_log.jsonl`` dosyasından kayip degerlerini okuyup matplotlib ile grafiklendirir. Loglardan gelen kayip degerleri adim bazinda gorsellestirilir. Egitim tamamlandiginda ``training_loss.png`` ve ``training_eval_loss.png`` gibi grafikleri incelemek mumkundur.

8. Model Yukleme ve Gradio Arayuzu

8.1. Model Yukleme

Egitilmiş LoRA adapteri, temel Qwen modeli üzerine yuklenir:

- Base model: `Qwen/Qwen2.5-3B-Instruct`
- Adapter: `/content/drive/MyDrive/llamafactory\_runs/atakan\_qa\_qwen2.5\_lora`

Model 4-bit olarak yuklenir:

```
AutoModelForCausalLM.from_pretrained(  
    BASE_MODEL_ID,  
    device_map="auto",  
    torch_dtype=torch.float16,  
    load_in_4bit=True  
)
```

8.2. Sistem Mesaji

Chat fonksiyonunda sistem rolü:

Sen Firat Universitesi akademik tesvik yönetmeliği konusunda uzman bir asistansın. Cevaplar sadece yönetmelik ve başvuru rehberine dayanarak, resmi ve net bir dille ver.

8.3. Gradio UI

Gradio arayuzunde su girdiler vardır:

- Soru metni (Textbox)
- Temperature (0.1 - 1.0)
- Maksimum token (64 - 1024)

Arayuz başlığı: "Akademik Tesvik Asistani"

9. Veri ve Artefaktlar

9.1. Veri Dosyaları

- `data/dataset.csv`: NotebookLM üretimi ham veri
- `data/atakan\_qa.json`: Alpaca formatlı eğitim verisi (1000 kayıt)
- `data/dataset\_info.json`: LlamaFactory dataset konfigürasyonu

9.2. Model Artefaktları

Eğitim sonrası üretilecek örnek artefaktlar:

- LoRA adapter ağırlıkları

- training_log.txt
- trainer_log.jsonl
- training_loss.png

10. Dizin Yapısının Ayrıntılı Açıklaması

```
firat-akademik-tesvik-llm/  
■■■ docs/                # Kaynak dokumanlar ve teknik dokuman  
■■■ data/                # Ham ve işlenmiş datasetler  
■■■ notebooks/           # Colab eğitim notebooku  
■■■ readme.md            # Proje özet dokuman  
■■■ test.jpg             # Gradio arayüz görseli
```

11. Güvenlik, Etik ve Uyumluluk

- Yanıtlar resmi dokumana dayandırılmalıdır.
- Model, doğrudan hukuki ya da idari karar aracı değildir.
- Kullanıcı verisi ile eğitim süreci yoktur; sadece dokuman tabanlı QA seti kullanılır.

12. Tekrar Edilebilirlik ve Çalıştırma Adımları

1. Kaynak dokumanları `docs/` altına yerleştir. 2. NotebookLM ile `data/dataset.csv` üret. 3. `Training\_Colab.ipynb` üzerinden CSV -> JSON dönüşümünü çalıştır. 4. `train\_config.yaml` ayarlarını oluştur. 5. LlamaFactory ile QLoRA eğitimini çalıştır. 6. LoRA adapter ile Gradio arayüzünü başlat.

13. Bilinen Riskler ve Sorun Giderme

- GPU bulunamazsa eğitim başlatılamaz (Colab runtime GPU ayarı kontrol edilmeli).
- CSV encoding uyumsuzluğu verinin okunmasını engeller; UTF-8 veya CP1254 ile tekrar kaydetmek gerekir.
- Drive yazma izinleri yoksa log ve model çıktıları kaydedilemez.
- Model yanıtları dokuman dışına tasabilir; prompt sistem rolü ile sınırlandırılır.

14. Gelecek İyileştirmeler

- Daha büyük ve çeşitli QA veri seti.
- Değerlendirme için otomatik metrikler ve insan doğrulama akışı.
- Modeli bir REST API olarak servis etme.
- Kurumci kimlik doğrulaması veya yetkilendirme eklenmesi.

15. Lisans ve Atif

- Lisans: MIT (detaylar ``LICENSE`` dosyasında)
- Atif önerisi: ``readme.md`` içindeki BibTeX kaydı.